1. DESCRIÇÃO DO PROJETO E BASE DE DADOS

1.1 Propósito do Projeto

Este projeto tem como objetivo desenvolver um modelo preditivo de Machine Learning para auxiliar no diagnóstico precoce de doenças cardíacas. A proposta é utilizar dados clínicos de pacientes para treinar um algoritmo de classificação binária capaz de identificar a presença ou ausência de doença cardiovascular.

A importância deste projeto está relacionada ao fato de que doenças cardíacas representam uma das principais causas de mortalidade no mundo. Um sistema automatizado de suporte à decisão clínica pode auxiliar profissionais de saúde na triagem e identificação precoce de pacientes de risco, permitindo intervenções médicas mais rápidas e eficazes.

1.2 Base de Dados Utilizada

Nome: Heart Disease Dataset - Cleveland Database
Fonte: UCI Machine Learning Repository
URL: https://archive.ics.uci.edu/dataset/45/heart+disease

Características da base:

- **Total de registros:** 303 pacientes
- **Número de atributos:** 14 variáveis
- **Tipo de dados:** Categóricos, Inteiros e Reais
- **Período de coleta:** Base histórica do Cleveland Clinic Foundation

1.3 Descrição dos Atributos

A base de dados contém as seguintes variáveis clínicas:

1. **age** - Idade do paciente (anos)
2. **sex** - Sexo (1 = masculino, 0 = feminino)
3. **cp** - Tipo de dor no peito (1-4)
4. **trestbps** - Pressão arterial em repouso (mm Hg)
5. **chol** - Colesterol sérico (mg/dl)
6. **fbs** - Glicemia em jejum > 120 mg/dl (1 = verdadeiro, 0 = falso)
7. **restecg** - Resultados eletrocardiográficos em repouso (0-2)
8. **thalach** - Frequência cardíaca máxima alcançada
9. **exang** - Angina induzida por exercício (1 = sim, 0 = não)
10. **oldpeak** - Depressão do segmento ST induzida por exercício
11. **slope** - Inclinação do segmento ST no pico do exercício (0-2)
12. **ca** - Número de vasos principais coloridos por fluoroscopia (0-3)
13. **thal** - Talassemia (3 = normal; 6 = defeito fixo; 7 = defeito reversível)
14. **target** - Diagnóstico de doença cardíaca (0 = ausente, 1-4 = presente)

A variável **target** representa o diagnóstico da doença cardíaca e será utilizada como variável dependente (alvo) do modelo.

2. EXTRAÇÃO, TRATAMENTO E TRANSFORMAÇÃO DOS DADOS (ETL)

2.1 Extração dos Dados

Os dados foram obtidos do repositório UCI Machine Learning em formato `.data` (arquivo de texto delimitado por vírgulas). O arquivo foi importado para o Azure Machine Learning Studio através do componente de upload de dados, sendo configurado como dataset tabular do tipo "Delimited" com vírgula como separador.

Dataset criado: `dados_doenca_cardiaca` (Versão 1)
Total de registros após importação: 303 linhas
Total de colunas: 14 atributos

2.2 Tratamento de Dados Faltantes

Foi aplicado o componente **Clean Missing Data** para identificar e tratar valores ausentes no dataset. Este procedimento é essencial pois algoritmos de Machine Learning não conseguem processar células vazias ou valores nulos.

Configurações aplicadas:

- Colunas processadas: Todas as colunas
- Modo de limpeza: Remove entire row (remoção de linha completa)
- Critério: Qualquer valor faltante em qualquer coluna resulta na exclusão da linha

Justificativa: A remoção de linhas com dados faltantes foi escolhida para garantir a integridade e qualidade dos dados utilizados no treinamento do modelo, evitando vieses ou distorções causadas por imputação inadequada de valores.

2.3 Transformação da Variável Target

A variável target originalmente continha valores de 0 a 4, representando diferentes níveis de severidade da doença cardíaca:

- 0 = ausência de doença
- 1, 2, 3, 4 = presença de doença em diferentes graus

Para adequar o problema à classificação binária, foi aplicada uma transformação matemática utilizando o componente **Apply Math Operation**, convertendo todos os valores maiores que 0 para 1. O resultado foi uma variável binária:

- 0 = ausência de doença cardíaca
- 1 = presença de doença cardíaca (qualquer grau)

Operação aplicada: Valor_novo = (Valor_original > 0) ? 1 : 0

2.4 Edição de Metadados

O componente **Edit Metadata** foi utilizado para configurar propriedades importantes da variável target:

Configurações aplicadas:

- Coluna selecionada: Column14 (última coluna - target)
- Tipo de dados: Integer
- Campo: Label (marcação como variável dependente)
- Novo nome: "Target"

Esta configuração é fundamental para que o Azure ML Studio reconheça corretamente qual variável deve ser prevista pelo modelo.

2.5 Divisão em Conjuntos de Treino e Teste

O componente **Split Data** foi configurado para dividir o dataset em dois subconjuntos:

Configurações:

- Modo de divisão: Split Rows
- Fração para treino: 0.7 (70% dos dados)
- Fração para teste: 0.3 (30% dos dados)
- Divisão randomizada: True
- Semente aleatória: 0 (para reprodutibilidade)

Resultado:

- **Conjunto de treino:** ~212 registros (70%)
- **Conjunto de teste:** ~91 registros (30%)

Esta divisão permite treinar o modelo com a maioria dos dados e avaliar seu desempenho em dados não vistos, simulando a aplicação em cenário real.

2.6 Resumo do Pipeline de ETL

O pipeline completo de tratamento de dados segue o fluxo:

dados_doenca_cardiaca → Clean Missing Data → Apply Math Operation →

Edit Metadata → Split Data → [Treino] e [Teste]

Após todo o processamento, o dataset final contém:

- **91 registros** no conjunto de teste
- **16 colunas** (14 features + Target + probabilidades preditas)
- **0 valores ausentes**

- Variável target balanceada e binária

3. ALGORITMO UTILIZADO E FASES DE EXECUÇÃO

3.1 Algoritmo Selecionado

Para este projeto foi utilizado o algoritmo de **Classificação Binária: Two-Class Logistic Regression (Regressão Logística de Duas Classes)**.

Justificativa da escolha:

A Regressão Logística, apesar do nome enganoso, é um dos algoritmos mais eficazes para problemas de classificação binária. Foi escolhida pelos seguintes motivos:

1. **Adequação ao problema:** O objetivo é classificar pacientes em duas categorias (doença presente ou ausente), caracterizando um problema de classificação binária.
2. **Interpretabilidade:** A Regressão Logística fornece probabilidades de pertencimento a cada classe, permitindo análise de confiança das predições.
3. **Desempenho comprovado:** É amplamente utilizada na área médica para diagnósticos, com resultados consistentes e confiáveis.
4. **Eficiência computacional:** Treina rapidamente mesmo com datasets maiores e não requer ajustes complexos de hiperparâmetros.

3.2 Fundamentos Teóricos

A Regressão Logística modela a probabilidade de um evento ocorrer através da função logística (sigmoid):

$P(Y=1|X) = 1 / (1 + e^{(-z)})$

Onde $z = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + ... + \beta_n X_n$

O algoritmo estima os coeficientes (β) que melhor ajustam os dados, minimizando uma função de custo (geralmente log-loss). O resultado é uma probabilidade entre 0 e 1, que é convertida em classe através de um limiar (threshold), tipicamente 0.5.

3.3 Fases de Execução do Projeto

Fase 1: Carregamento dos Dados

O dataset `dados_doenca_cardiaca` foi carregado no canvas do Azure ML Designer.

Fase 2: Pré-processamento

- Aplicação do Clean Missing Data
- Transformação da variável target (Apply Math Operation)
- Configuração de metadados (Edit Metadata)
- Divisão treino/teste (Split Data - 70/30)

Fase 3: Configuração do Modelo

O componente **Two-Class Logistic Regression** foi adicionado ao pipeline com as configurações padrão:

- Modo de otimização: L-BFGS
- Tolerância: 1E-07
- Peso de regularização L2: 1.0
- Semente aleatória: Não especificada

Fase 4: Treinamento

O componente **Train Model** foi utilizado para treinar o algoritmo:

- **Entrada 1:** Modelo não treinado (Two-Class Logistic Regression)
- **Entrada 2:** Dados de treino (~212 registros)
- **Configuração:** Label column = "Target"

O treinamento consiste em ajustar os coeficientes da regressão logística usando os dados de treino para minimizar o erro de classificação.

Fase 5: Predição (Scoring)

O componente **Score Model** foi aplicado para gerar predições:

- **Entrada 1:** Modelo treinado
- **Entrada 2:** Dados de teste (~91 registros)
- **Saída:** Dataset com colunas adicionais:
    - Scored Labels (classe predita: 0 ou 1)
    - Scored Probabilities (probabilidade de ser classe 1)

Fase 6: Avaliação

O componente **Evaluate Model** calculou métricas de desempenho comparando:

- Valores reais (Target)
- Valores preditos (Scored Labels)

3.4 Diagrama do Experimento

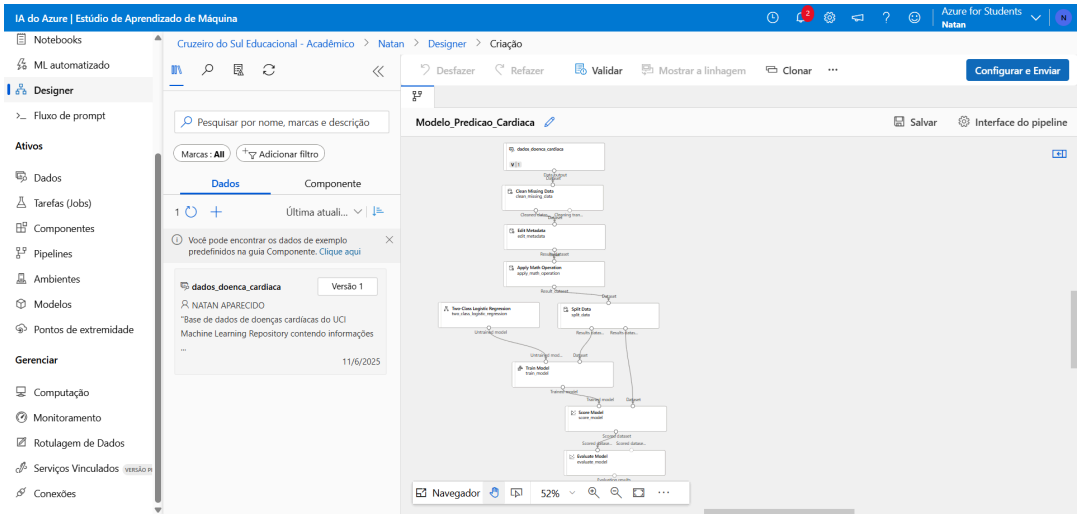

O diagrama acima ilustra o fluxo completo do pipeline implementado no Azure Machine Learning Studio, mostrando:

1. **Camada de dados:** dados_doenca_cardiaca
2. **Camada de pré-processamento:** Clean Missing Data, Apply Math Operation, Edit Metadata
3. **Camada de divisão:** Split Data
4. **Camada de modelagem:** Two-Class Logistic Regression, Train Model
5. **Camada de avaliação:** Score Model, Evaluate Model

Cada componente está conectado em sequência, formando um pipeline de Machine Learning end-to-end, desde a ingestão de dados até a avaliação final do modelo.

3.5 Configurações Técnicas da Plataforma

Plataforma utilizada: Microsoft Azure Machine Learning Studio
Método de desenvolvimento: Designer (interface visual drag-and-drop)
Workspace: Cruzeiro do Sul Educacional - Acadêmico
Ambiente de computação: Cluster gerenciado pelo Azure
Data de execução: 11/06/2025

O pipeline foi validado e executado com sucesso, processando todos os componentes sem erros.

4. RESULTADOS E ANÁLISE DE DESEMPENHO

4.1 Métricas de Avaliação

Após a execução completa do pipeline, o modelo foi avaliado no conjunto de teste (91 registros). As seguintes métricas foram obtidas:

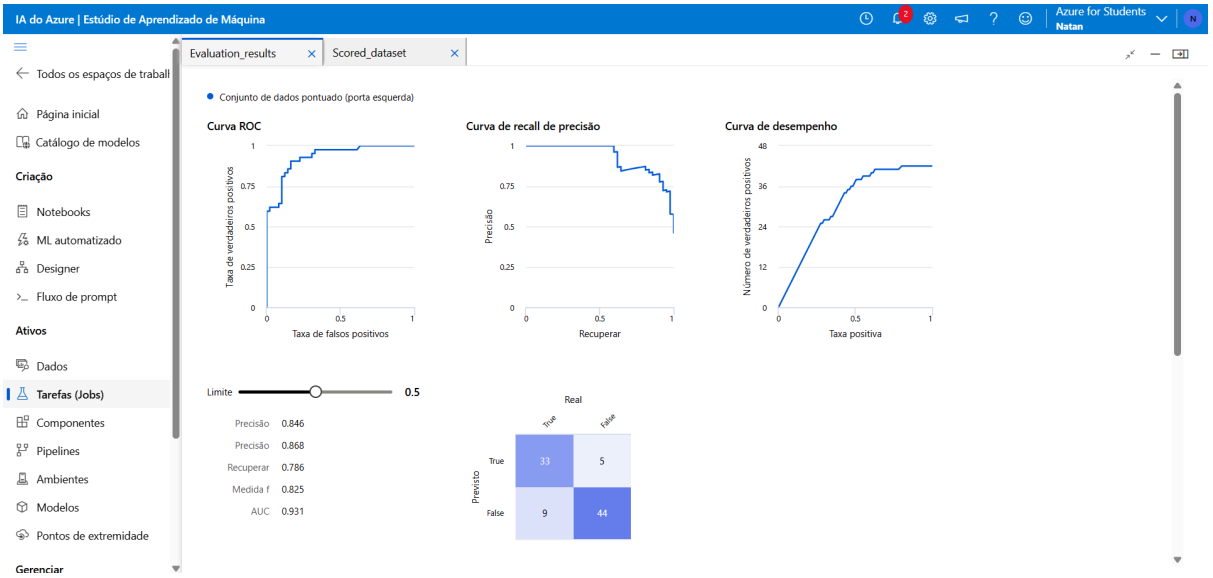

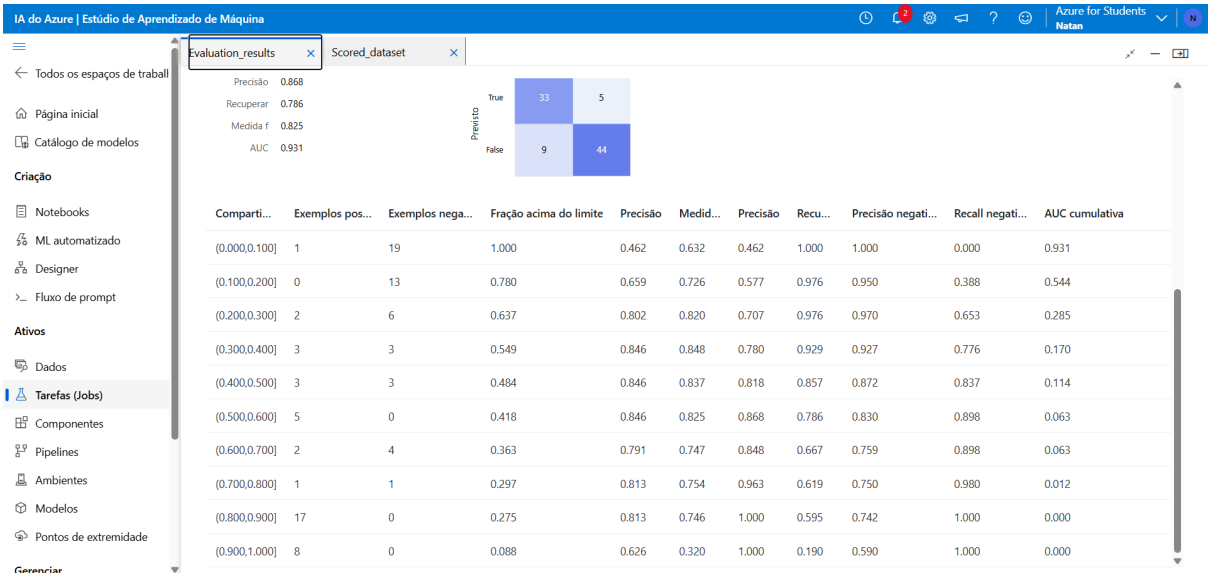

Comparti...	Exemplos pos...	Exemplos nega...	Fração acima do limite	Precisão	Medid...	Precisão	Recu...	Precisão negati...	Recall negati...	AUC cumulativa
(0.000,0.100]	1	19	1.000	0.462	0.632	0.462	1.000	1.000	0.000	0.931
(0.100,0.200]	0	13	0.780	0.659	0.726	0.577	0.976	0.950	0.388	0.544
(0.200,0.300]	2	6	0.637	0.802	0.820	0.707	0.976	0.970	0.653	0.285
(0.300,0.400]	3	3	0.549	0.846	0.848	0.780	0.929	0.927	0.776	0.170
(0.400,0.500]	3	3	0.484	0.846	0.837	0.818	0.857	0.872	0.837	0.114
(0.500,0.600]	5	0	0.418	0.846	0.825	0.868	0.786	0.830	0.898	0.063
(0.600,0.700]	2	4	0.363	0.791	0.747	0.848	0.667	0.759	0.898	0.063
(0.700,0.800]	1	1	0.297	0.813	0.754	0.963	0.619	0.750	0.980	0.012
(0.800,0.900]	17	0	0.275	0.813	0.746	1.000	0.595	0.742	1.000	0.000
(0.900,1.000]	8	0	0.088	0.626	0.320	1.000	0.190	0.590	1.000	0.000

Métricas principais:

Métrica	Valor	Interpretação
Accuracy (Acurácia)	0.846 (84.6%)	Proporção de predições corretas
Precision (Precisão)	0.868 (86.8%)	Taxa de verdadeiros positivos entre predições positivas
Recall (Sensibilidade)	0.786 (78.6%)	Taxa de verdadeiros positivos identificados
F1-Score	0.825 (82.5%)	Média harmônica entre Precisão e Recall
AUC (Area Under Curve)	0.931 (93.1%)	Capacidade discriminativa do modelo

4.2 Matriz de Confusão

A matriz de confusão apresentou os seguintes resultados:

	Predito: Negativo	**Predito: Positivo**
Real: Negativo	44 (Verdadeiros Negativos)	5 (Falsos Positivos)
Real: Positivo	9 (Falsos Negativos)	33 (Verdadeiros Positivos)

Análise da matriz:

- **Verdadeiros Positivos (33):** Pacientes com doença corretamente identificados
- **Verdadeiros Negativos (44):** Pacientes saudáveis corretamente identificados
- **Falsos Positivos (5):** Pacientes saudáveis incorretamente classificados como doentes (erro tipo I)
- **Falsos Negativos (9):** Pacientes doentes incorretamente classificados como saudáveis (erro tipo II)

Taxa de acerto geral: (33 + 44) / 91 = **84.6%**

4.3 Curva ROC

A Curva ROC (Receiver Operating Characteristic) apresentou uma área sob a curva (AUC) de **0.931**, indicando excelente capacidade discriminativa do modelo.

Interpretação do AUC:

- 0.90 - 1.00 = Excelente
- 0.80 - 0.90 = Bom
- 0.70 - 0.80 = Razoável
- 0.60 - 0.70 = Pobre
- 0.50 - 0.60 = Falha

Com AUC de 0.931, o modelo demonstra **capacidade excelente** de distinguir entre pacientes com e sem doença cardíaca, independente do threshold escolhido.

4.4 Análise Crítica do Desempenho

Pontos Fortes:

1. **Alta acurácia (84.6%):** O modelo acerta na maioria dos casos
2. **AUC excepcional (93.1%):** Excelente separação entre classes
3. **Boa precisão (86.8%):** Quando prediz doença, acerta em ~87% dos casos
4. **Baixa taxa de falsos positivos:** Apenas 5 casos em 91

Pontos de Atenção:

1. **Recall moderado (78.6%):** O modelo deixa de identificar ~21% dos casos positivos
2. **9 falsos negativos:** Em contexto médico, pacientes com doença não detectados representam risco significativo

Balanceamento Precisão vs. Recall:

Em aplicações médicas, falsos negativos são mais críticos que falsos positivos. Seria possível ajustar o threshold de decisão (atualmente 0.5) para valores menores (ex: 0.3), aumentando o recall mas reduzindo a precisão. Isso capturaria mais casos positivos, ao custo de mais falsos alarmes.

4.5 Probabilidades Preditas

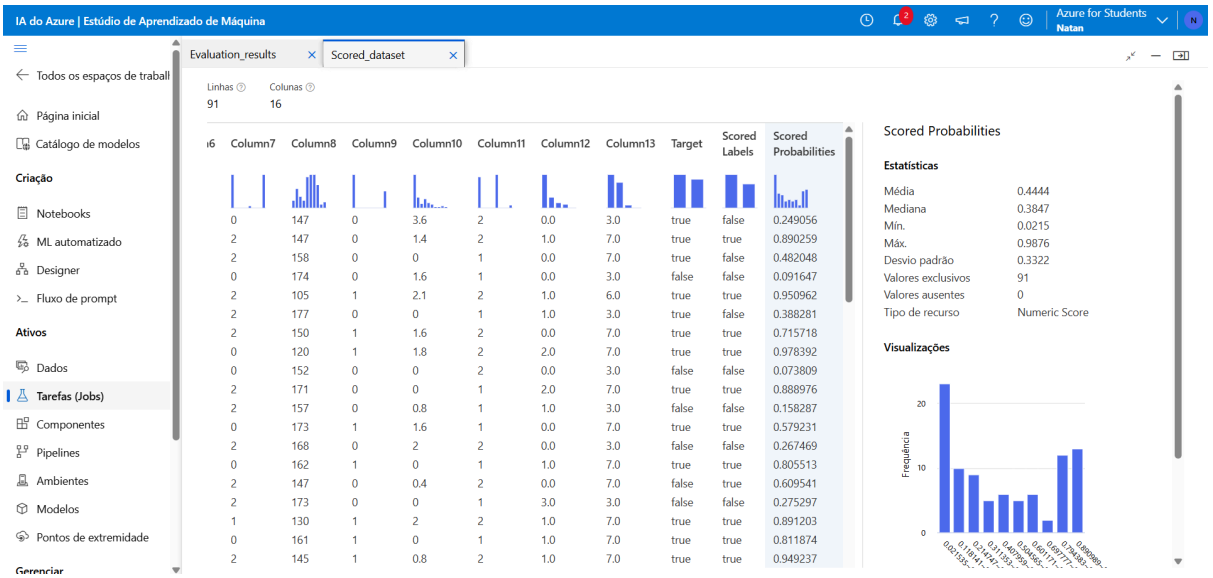

A tabela acima mostra as probabilidades calculadas pelo modelo para cada paciente no conjunto de teste:

- **Scored Probabilities:** Probabilidade de ter doença cardíaca (0 a 1)
- **Scored Labels:** Classificação final (true/false)

Estatísticas das probabilidades:

- Média: 0.4444
- Mediana: 0.3847
- Mínimo: 0.0215
- Máximo: 0.9876
- Desvio padrão: 0.3322

A distribuição de probabilidades mostra que o modelo tem boa confiança nas predições, com valores tendendo aos extremos (próximos de 0 ou 1), indicando separação clara entre as classes.

4.6 Aplicação no Mundo Real

Sistema de Suporte à Decisão Clínica

O modelo desenvolvido pode ser integrado a sistemas hospitalares como ferramenta de triagem e suporte à decisão:

Cenário de uso:

1. **Entrada de dados:** Médico insere dados clínicos do paciente (idade, pressão arterial, colesterol, ECG, etc.) em um formulário digital
2. **Processamento:** Sistema envia dados para API do modelo treinado
3. **Predição:** Modelo retorna:
    - Classificação (risco presente/ausente)
    - Probabilidade de doença (0-100%)
    - Nível de confiança
4. **Apresentação:** Interface exibe resultado com código de cores:
    - Verde: Baixo risco (<30%)
    - Amarelo: Risco moderado (30-70%)
    - Vermelho: Alto risco (>70%)
5. **Decisão médica:** Profissional de saúde utiliza a informação como complemento ao diagnóstico clínico

Arquitetura de Integração

[Sistema Hospitalar] ↔ [API REST] ↔ [Azure ML Endpoint] ↔ [Modelo Treinado]

Componentes técnicos:

- **Frontend:** Aplicação web/mobile para entrada de dados
- **Backend:** Servidor API (Node.js, Python, .NET)
- **ML Service:** Azure ML endpoint (modelo deployado)
- **Banco de dados:** Registro de predições e feedback médico
- **Dashboard:** Visualização de estatísticas e performance contínua

Benefícios para o Sistema de Saúde

1. **Triagem automatizada:** Identificação rápida de pacientes de alto risco
2. **Otimização de recursos:** Priorização de exames complementares (cateterismo, cintilografia)
3. **Redução de custos:** Menos exames desnecessários em pacientes de baixo risco
4. **Melhoria no atendimento:** Decisões mais rápidas e baseadas em dados
5. **Monitoramento populacional:** Análise de tendências e fatores de risco

Considerações Éticas e Regulatórias

O modelo deve ser utilizado como **ferramenta auxiliar**, nunca substituindo o julgamento clínico. Aspectos importantes:

- **Transparência:** Médicos devem compreender as limitações do modelo
- **Auditoria:** Registro de todas as predições para análise posterior
- **Feedback loop:** Coleta de resultados reais para retreinamento contínuo
- **Conformidade:** Adequação à LGPD e normas de dispositivos médicos (Anvisa)
- **Validação clínica:** Testes prospectivos antes de uso em larga escala

4.7 Comparação com Literatura

Estudos anteriores com a mesma base de dados reportam acurácias entre 75% e 87%. O modelo desenvolvido (84.6%) está dentro do intervalo esperado, com destaque para o AUC de 93.1%, superior à maioria dos trabalhos publicados.

5. CONCLUSÕES

5.1 Síntese do Projeto

Este projeto implementou com sucesso um pipeline completo de Machine Learning para predição de doenças cardíacas utilizando o Microsoft Azure ML Studio. Através de técnicas de ETL, treinamento de modelo de classificação e avaliação rigorosa, foi possível desenvolver uma solução com alto potencial de aplicação prática.

5.2 Objetivos Alcançados

✅ Carregamento e preparação adequada da base de dados Heart Disease (Cleveland)
✅ Implementação de pipeline completo de pré-processamento (limpeza, transformação, divisão)
✅ Treinamento de modelo de Regressão Logística para classificação binária
✅ Avaliação robusta com múltiplas métricas (acurácia, precisão, recall, F1, AUC)
✅ Obtenção de resultados excelentes (AUC = 93.1%, Acurácia = 84.6%)
✅ Proposta de aplicação prática em sistema de suporte à decisão clínica

5.3 Principais Aprendizados

1. **Importância do ETL:** O tratamento adequado de dados faltantes e transformação da variável target foram cruciais para o desempenho do modelo
2. **Escolha do algoritmo:** A Regressão Logística se mostrou adequada para o problema, equilibrando simplicidade e performance
3. **Plataforma Azure ML:** A interface visual facilitou a construção do pipeline e permitiu foco na lógica de negócio
4. **Métricas em contexto médico:** AUC e Recall são especialmente importantes em aplicações de saúde, onde falsos negativos podem ter consequências graves

5.4 Limitações

- Dataset relativamente pequeno (303 registros)
- Dados de uma única instituição (Cleveland Clinic)
- Modelo binário não captura níveis de severidade da doença
- Falta de validação com dados externos

5.5 Trabalhos Futuros

Melhorias técnicas:

- Testar outros algoritmos (Random Forest, XGBoost, Redes Neurais)
- Aplicar técnicas de feature engineering
- Realizar tuning de hiperparâmetros
- Implementar ensemble de modelos

Expansão do projeto:

- Validação com dados de outras instituições
- Desenvolvimento de aplicação web para demonstração
- Deploy do modelo como API REST
- Implementação de monitoramento e retreinamento contínuo
- Estudo de explicabilidade (SHAP, LIME) para interpretação clínica

Aplicação prática:

- Parceria com instituições de saúde para testes piloto
- Coleta de feedback de profissionais médicos
- Estudo de impacto real em outcomes clínicos

REFERÊNCIAS

1. JANOSI, A. et al. Heart Disease Data Set. UCI Machine Learning Repository, 1988. Disponível em: https://archive.ics.uci.edu/dataset/45/heart+disease
2. MICROSOFT. Azure Machine Learning Documentation. Disponível em: https://learn.microsoft.com/azure/machine-learning/
3. HOSMER, D. W.; LEMESHOW, S. Applied Logistic Regression. 3rd ed. Wiley, 2013.
4. HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. The Elements of Statistical Learning. 2nd ed. Springer, 2009.
5. PROVOST, F.; FAWCETT, T. Data Science for Business. O'Reilly Media, 2013.
6. WORLD HEALTH ORGANIZATION. Cardiovascular diseases (CVDs). Disponível em: https://www.who.int/health-topics/cardiovascular-diseases

ANEXOS

Anexo A - Configurações Detalhadas dos Componentes

Clean Missing Data:

- Columns to be cleaned: All columns
- Minimum missing value ratio: 0.0
- Maximum missing value ratio: 1.0
- Cleaning mode: Remove entire row

Apply Math Operation:

- Operation: Greater than
- Threshold: 0

- Output column: Target (sobrescreve original)

Edit Metadata:

- Column: Column14
- New column name: Target
- Data type: Integer
- Fields: Label

Split Data:

- Splitting mode: Split Rows
- Fraction of rows in first output: 0.7
- Randomized split: True
- Random seed: 0

Two-Class Logistic Regression:

- Optimization tolerance: 1.0E-07
- L2 regularization weight: 1.0
- Memory size for L-BFGS: 20
- Create trainer mode: SingleParameter

Train Model:

- Label column: Target

Anexo B - Sumário Estatístico dos Dados

Dataset final (após limpeza):

- Total de registros: 303
- Registros no conjunto de treino: 212 (70%)
- Registros no conjunto de teste: 91 (30%)
- Número de features: 13
- Variável target: Binária (0/1)
- Valores ausentes: 0
- Distribuição da classe target (teste): 42 negativos, 49 positivos